

UNIVERSIDADE DE SÃO PAULO

ISADORA RUSSO FRIEDERICKS

LUÍS ZUCCHI DE SOUZA

SALÁRIO MÍNIMO E CRIMINALIDADE

São Paulo-SP

2023

1. Introdução

O salário mínimo, enquanto política social implementada em diversos países do mundo, garante um nível mínimo de renda para trabalhadores com contratos de trabalho, assegurando assim condições de vida suficientes para indivíduos abrangidos por essa política. Um possível efeito decorrente do aumento do piso salarial, que não é evidente e amplamente discutido na literatura, é o seu uso como estratégia de combate à criminalidade, como aponta um relatório de 2016 do CEA (Council of Economic Advisers) da Casa Branca (FONE et al., 2019), assim como sua maior eficiência em termos de custos em relação a práticas tradicionais relacionadas à justiça criminal. Segundo o relatório, o aumento do salário de trabalhadores de baixa qualificação causado por um incremento no salário mínimo impactaria o custo de oportunidade de atividades criminais, assim diminuindo a entrada dessa classe no crime.

Contudo, uma das consequências mais discutidas dessa política na literatura econômica é o seu impacto sobre o nível de desemprego, que aumentaria por conta da elevação dos custos de contratação de empregados. Assim, o efeito supracitado pode ser mitigado ou até sobreposto, isto é, o aumento no salário mínimo pode ter como resultado um incremento no nível de criminalidade, ao diminuir o número de trabalhadores com contrato formal de trabalho, invalidando a hipótese de que a política de salário mínimo impacta negativamente a criminalidade.

Diante do exposto, o presente trabalho se dispõe a averiguar a hipótese de que a política de salário mínimo promove uma redução no nível de criminalidade, levando em consideração o possível efeito contrário relacionado ao impacto da política sobre o desemprego e estimar tal magnitude, tendo como área de análise o estado de São Paulo e o período de 1999 a 2014, excetuando-se os anos de 2000 e 2010.

2. Metodologia e dados

2.1. Seleção de variáveis e origem dos dados

Para modelarmos a variável de interesse de nossa análise, isto é, a criminalidade, utilizaremos dados de ocorrências policiais anuais de homicídio doloso, furto, roubo e furto e roubo de veículo fornecidas pela Secretaria de Segurança Pública do Estado de São Paulo. Método semelhante é aplicado por Fone et al. (2019) em artigo que tem proposta equivalente à nossa, no qual foi definido como variável dependente para seu modelo a taxa de prisões por 1000 habitantes de 16 a 24 anos, para crimes à propriedade, crimes violentos e crimes leves. Em nosso modelo, selecionamos apenas as ocorrências dos tipos de crimes supracitados por conta de limitações na disponibilidade de dados. Para nossa análise, somamos o número total dessas

ocorrências por ano, e utilizamos o dado obtido como variável proxy para a criminalidade, por representar de forma absoluta o número de ocorrências dos crimes selecionados. Beauchamp e Chan (2014) partem do mesmo princípio, ao utilizar o número de crimes anuais reportados pelo National Longitudinal Survey of Youth, censo que coleta informações que incluem atividades criminais. O período abrangido pelo nosso conjunto de dados é de 1999 a 2023, porém selecionamos o intervalo de 1999 a 2014, excetuando-se os anos de 2000 e 2010, por conta de limitações relacionadas à disponibilidade de dados dos bancos que serão apresentados a seguir. O período soma 14 anos, número de observações igual ao empregado por Beauchamp e Chan (2014), que fez sua análise a partir de dados de 1997 a 2010.

Para a variável independente chave de nossa análise, o salário mínimo, utilizaremos a série histórica dos anos 1999 até 2014, excluindo-se os anos de 2000 e 2010, para o salário mínimo nominal, obtida a partir do IPEA (Instituto de Pesquisa Econômica Aplicada) e da Secretaria de Desenvolvimento Econômico de São Paulo conjuntamente. Por termos como área de análise o Estado de São Paulo, que possui valores de salário mínimo próprios a partir de 2007, utilizamos os valores do salário mínimo federal de 1999 a 2006, excetuando-se 2000 e 2010, fornecidos pelo IPEA, e para os valores de 2007 a 2014 empregamos os valores da Faixa 1 do salário mínimo do Estado de São Paulo fornecidos pela Secretaria de Desenvolvimento, sendo 2007 o ano em que passou a valer o salário mínimo estadual. Selecionamos a Faixa 1 por se tratar do piso salarial que engloba a maior parte dos trabalhadores que recebem salário mínimo. Fone et al. (2019) aplica o mesmo princípio que utilizamos para substituir os valores do salário mínimo federal pelo do estado de São Paulo em sua metodologia, ao selecionar o maior valor entre os salários mínimos federal, estadual ou local. Realizamos o deflacionamento da série obtida a partir da série de variação do IPCA (Índice Nacional de Preços ao Consumidor Amplo), também fornecido pelo IPEA, que mede a variação dos preços da cesta de consumo das famílias residentes na região de abrangência do SNIPC (Sistema Nacional de Índices de Preços ao Consumidor). O método de deflacionamento utilizado foi o descrito por DeLosso (2020), tomando o ano de 2014 como base. O período selecionado foi o mesmo da variável explicada, criminalidade.

Como demais variáveis independentes que possivelmente explicam a criminalidade, selecionamos a taxa de desemprego, que é o percentual das pessoas que procuraram mas não encontraram ocupação profissional remunerada entre a população economicamente ativa, assim como Fone et al. (2019) emprega, de forma análoga, em seu modelo: a taxa de desemprego para homens entre 25 e 54 anos; o grau de informalidade, calculado como a razão entre o número de empregados sem carteira e trabalhadores por conta própria dividido pelo número de trabalhadores protegidos somados ao número de empregados sem carteira e à quantidade de

trabalhadores por conta própria, e é variável empregada por Pinto et al. (2018) em estudo que analisa os determinantes da taxa de criminalidade; o número de anos de estudo, calculado como a razão entre o somatório do número de anos de estudo completados pelas pessoas que tem 25 ou mais anos de idade e o número de pessoas nessa faixa etária, sendo uma variável proxy para escolaridade, que também é empregada por Pinto et al. (2018), que por sua vez utiliza a taxa de escolaridade média; o coeficiente de Gini, o qual mede o nível de desigualdade de uma população segundo a renda domiciliar per capita, variável também empregada por Pinto et al. (2018); o número de domicílios pobres, se tratando do número de residências com renda domiciliar per capita inferior à linha de pobreza, definida segundo recomendações da FAO (Organização das Nações Unidas para a Alimentação e a Agricultura) e da OMS (Organização Mundial da Saúde), se tratando de uma variável proxy para a pobreza, que entra no estudo de Pinto et al. (2018); e o valor nominal total das transferências em dezembro de cada ano do programa Bolsa Família, que entrou em vigor no ano de 2004. A justificativa do uso dessa variável foi baseada em Fone et al. (2019) e Pinto et al. (2018), que utilizam em seus modelos dados de programas sociais voltados ao bem estar social. A fonte dos dados de todas as variáveis citadas é o repositório da SEADE (Fundação Sistema Estadual de Análise de Dados), e o período disponível era de 1999 a 2014, tendo os anos de 2000 e 2010 como omissos, por isso a restrição imposta à construção de nosso conjunto de dados.

Por fim, incluímos também o PIB (Produto Interno Bruto) do Estado de São Paulo, cuja base de dados foi fornecida pelo SEADE, porém esta abrangia apenas o intervalo de 2002 a 2020. Para completar o período que tínhamos encontrado nas outras bases, obtivemos os valores do PIB do estado de 1999 e 2001 a partir dos relatórios de Contas Regionais do Brasil de 1999 e de 2001 do IBGE (Instituto Brasileiro de Geografia e Estatística), respectivamente. Assim, nosso conjunto de dados foi composto por uma variável dependente e oito variáveis independentes, contemplando o período de 1999 a 2014, excetuando-se os anos de 2000 e 2010. A série do PIB e de valores repassados do Bolsa Família foram deflacionadas pelo mesmo método empregado para a série de salário mínimo, baseado em DeLosso (2019), e utilizando-se o ano de 2014 como base.

A combinação dos dados de salário mínimo real e ocorrências policiais nos permitirá investigar possíveis relações entre a remuneração mínima e a incidência de crimes específicos no Estado de São Paulo. A análise empírica será conduzida por meio de técnicas econométricas, uma regressão linear múltipla, controlando variáveis de controle relevantes que serão desenvolvidas abaixo.

2.2. Características dos Dados e Tratamento para Análise

Após a determinação das variáveis explicadas e explicativas com base em Fone et al. (2019) e Beauchamp e Chan (2014), e a extração de suas base de dados, foi necessário uni-las em um único *dataframe*, que apresenta em suas nove colunas a variável dependente e as independentes e em suas catorze linhas os anos nos quais os seus valores foram coletados, que abrangem em sequência cronológica os anos de 1999 a 2014, excluindo-se 2000 e 2010. O conjunto de dados trata-se de uma série temporal. Todas as variáveis apresentadas na nova tabela criada são contínuas e não possuem nenhum dado ausente, dessa forma, não foi preciso fazer nenhum tipo de tratamento para dados omissos. Entretanto, a variável Bolsa Família contará propositalmente com valores nulos nos períodos iniciais da série temporal, já que o programa só foi implementado no ano de 2004.

| | n_ocorrencias | Salario_Minimo | TaxaDesemprego | GrauInformalidade | AnosEstudo | CoefficienteGini | NDomiciliosPobres | PIB_SP | BolsaFamilia |
|------|---------------|----------------|----------------|-------------------|------------|------------------|-------------------|-----------|--------------|
| 1999 | 846389 | 137.4500 | 12.920109 | 45.57398 | 6.714719 | 0.5416729 | 1461560 | 340429.2 | 0 |
| 2001 | 889512 | 181.6481 | 11.451631 | 44.37829 | 6.964951 | 0.5531385 | 1695618 | 404297.1 | 0 |
| 2002 | 892108 | 201.6764 | 11.819351 | 45.27019 | 7.150758 | 0.5550697 | 1744310 | 523228.1 | 0 |
| 2003 | 986738 | 241.7088 | 12.596527 | 44.47536 | 7.305676 | 0.5457373 | 1930271 | 595665.3 | 0 |
| 2004 | 985669 | 261.6079 | 11.510959 | 43.19478 | 7.434944 | 0.5279760 | 1843902 | 656993.7 | 39653479 |
| 2005 | 993404 | 301.6261 | 11.761362 | 42.81420 | 7.548009 | 0.5321280 | 1586439 | 747070.4 | 49767031 |
| 2006 | 957642 | 351.6970 | 10.225033 | 41.47441 | 7.796276 | 0.5246518 | 1306899 | 828527.1 | 62663336 |
| 2007 | 911641 | 411.8585 | 9.521033 | 40.20903 | 7.941705 | 0.5064813 | 1253696 | 939894.5 | 73142557 |
| 2008 | 872964 | 451.8384 | 8.192806 | 38.00683 | 8.051524 | 0.4980843 | 1082902 | 1046769.3 | 74380199 |
| 2009 | 969979 | 506.7640 | 9.800680 | 37.46515 | 8.242956 | 0.4893579 | 1074727 | 1131030.9 | 95974010 |
| 2011 | 967177 | 601.4810 | 7.146408 | 34.80109 | 8.519217 | 0.4846461 | 910778 | 1440218.8 | 136623295 |
| 2012 | 985837 | 691.2536 | 6.374750 | 33.84645 | 8.715096 | 0.4929049 | 773850 | 1561865.9 | 166064036 |
| 2013 | 1021922 | 755.9303 | 6.668443 | 33.87300 | 8.758089 | 0.4936187 | 791784 | 1717351.9 | 187403359 |
| 2014 | 1055604 | 810.5190 | 7.896507 | 35.84632 | 8.916115 | 0.4933970 | 720017 | 1859386.7 | 205277723 |

Figura 1. *Dataframe* após tratamento.

2.3. Regressão linear Múltipla:

Em nosso estudo, iremos utilizar a técnica estatística de regressão linear múltipla para investigar a relação entre o número de ocorrências criminais e o conjunto de variáveis independentes anteriormente apresentados. A equação linear múltipla proposta é a seguinte:

$$n^{\circ} \text{ocorrências criminais} = \beta_0 + \beta_1 \text{salário mínimo} + \beta_2 \text{desemprego} + \beta_3 \text{grau de informalidade} + \beta_4 \text{anos de estudo} + \beta_5 \text{coeficiente de gini} + \beta_6 \text{pobreza} + \beta_7 \text{bolsa família} + \beta_8 \text{PIB} + u$$

Nessa equação, β_0 representa o coeficiente linear (intercepto) e $\beta_1, \beta_2, \beta_3, \beta_4, \beta_5, \beta_6, \beta_7$ e β_8 , representam os coeficientes de regressão para cada variável independente correspondente. O termo u é o erro do modelo em questão, ou seja, os fatores não observáveis.

2.4. Formulação de Hipóteses

Estabeleceremos hipóteses acerca dos coeficientes estimados de nossa regressão, baseando-as na teoria econômica e nos artigos utilizados como base. Esperamos que o intercepto da equação de regressão, o β_0 , apresente um valor positivo, já que a variável explicada criminalidade é mensurada pelo número de ocorrências criminais, que não admite valores negativos. Para a variável explicativa central de nossa análise, salário mínimo, presumimos que o valor de seu coeficiente, β_1 , seja negativo, já que o objetivo de nosso trabalho é verificar se a política de salário mínimo provoca uma redução no nível de criminalidade. No entanto, formulamos também a hipótese contrária, de que o salário mínimo causa um efeito positivo na criminalidade. Um possível motivo para esse fenômeno seria o efeito gerado pelo desemprego, que supostamente cresceria com o salário mínimo, como concluído por Fone et al. (2019). Já em relação à variável taxa de desemprego, supomos que o coeficiente β_2 seja positivo, ou seja, o crime estaria negativamente relacionado à taxa de desemprego (FONE et al., 2019, apud RAPHAEL, WINTER-EBMER, 2001; GOULD ET AL., 2002; MACHIN AND MEGHIR, 2004; LEVITT, 2004; OSTER AND AGELL, 2007; LIN, 2008; MUSTARD, 2010). Para a terceira variável explicativa, Grau de Informalidade, presumimos que seu coeficiente β_3 seja positivo (PINTO et al., 2018). Esperamos que a variável Anos de Estudo apresente um coeficiente β_4 negativo, como também supõe Fone et al. (2019). O coeficiente de Gini trata-se de uma variável cujo coeficiente β_5 é presumido para ser positivo, pois esperamos que um maior nível de desigualdade impacte positivamente a criminalidade (PINTO et al., 2018). Esses autores também supuseram que a pobreza impacta positivamente a criminalidade, portanto esperamos encontrar um β_6 positivo. Ainda usando-os como referência, esperamos que a variável bolsa família impacte negativamente a criminalidade, portanto esperamos um β_7 negativo. Já em relação ao PIB do estado, esperamos encontrar um coeficiente de β_8 negativo, pois esperamos que um crescimento maior do produto estado tenha um impacto que diminua a criminalidade (DETOTTO; OTRANTO, 2010).

2.5. Considerações na Estimação por MQO em Séries Temporais

Ao aplicar o Método dos Quadrados Ordinários (MQO) em séries temporais, é necessário ter alguns cuidados devido principalmente à natureza específica desse tipo de dado. As séries temporais apresentam características que podem violar as seis hipóteses assumidas pelo MQO, tornando necessário, dessa forma, se atentar e corrigir as problemáticas antes de realizar as análises da regressão.

Um dos principais cuidados a serem observados é a presença de heterocedasticidade, isto é, não ocorre o fenômeno em que “a variância do termo erro, u , condicionada às variáveis explicativas, é a mesma para todas as combinações dos resultados das variáveis explicativas” (WOOLDRIDGE, 2019, p. 114), assim violando a quinta hipótese estimador MQO, podendo levar a estimativas ineficientes. Assim, é importante verificar a presença de heterocedasticidade e considerar a utilização de estimadores robustos ou modelos que levem em conta essa heterogeneidade na variância. Outra questão é a estacionariedade das séries temporais, tal questão implica que a média e a variância dos dados não mudam ao longo do tempo. Se a série temporal não for estacionária, o MQO leva a estimativas inconsistentes, e, portanto, é necessário aplicar técnicas de diferenciação ou transformação para torná-la estacionária. Além disso, a presença de autocorrelação nas séries temporais também é outro problema que podemos encontrar nesse tipo de dado, já que diferentemente dos dados independentes e identicamente distribuídos assumidos pelo MQO, as observações em séries temporais tendem a estar autocorrelacionadas, podendo levar a estimativas inconsistentes. Uma forma de tratar isso é usando modelos autorregressivos ou modelos de médias móveis. As séries temporais também podem exibir padrões sazonais, isto é, variações regulares em determinados períodos de tempo. Dessa forma, devemos incorporar componentes sazonais no modelo de regressão, utilizando variáveis dummy sazonais, por exemplo, antes de rodar a regressão. Finalmente, é importante também estar atento a possíveis quebras estruturais nas séries temporais, isto é, mudanças abruptas no comportamento dos dados em um determinado ponto do tempo, isso poderá ser corrigido através da segmentação de dados, por exemplo.

3. Resultado e Discussão

3.1. Resultados

Utilizando o software R para realizar a regressão linear múltipla, através do comando *lm()*, que ajusta o modelo, e o comando *summary()*, que fornece um resumo estatístico dos resultados da regressão, obtivemos os coeficientes estimados para cada parâmetro. Além disso, pudemos observar os valores de R-quadrado, R-quadrado ajustado, F-estatístico e o p-valor, o que nos ajudará mais tarde a interpretar o modelo.

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  -8.597e+05  4.636e+05  -1.854  0.12285
Salario_Minimo -3.879e+02  3.219e+02  -1.205  0.28208
TaxaDesemprego  4.383e+04  7.917e+03   5.536  0.00264 **
GrauInformalidade -2.336e+04  6.920e+03  -3.376  0.01975 *
AnosEstudo     1.438e+05  4.173e+04   3.446  0.01831 *
CoeficienteGini  2.002e+06  6.212e+05   3.223  0.02338 *
NDomiciliosPobres 1.401e-01  3.244e-02   4.318  0.00758 **
PIB_SP         5.140e-03  1.356e-01   0.038  0.97122
BolsaFamilia    1.643e-03  3.856e-04   4.260  0.00802 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12200 on 5 degrees of freedom
Multiple R-squared:  0.9845,    Adjusted R-squared:  0.9597
F-statistic: 39.65 on 8 and 5 DF,  p-value: 0.0004189

```

Figura 2. Resultado da regressão.

A equação de regressão estimada, com base nos resultados obtidos, será, portanto:

nºocorrências criminais = - 859.719,3 - 387.9325 salário mínimo + 43.829,35 taxa de desemprego - 23.363,33 grau de informalidade + 143.820,6 anos de estudo + 2.002.340 coeficiente gini + 0,140083 nº de domicílios pobres + 0,005140337 PIB SP + 0,001642811 bolsa família




Figura 3. Gráfico da Regressão Linear Múltipla.

Analisando a Regressão Linear Múltipla que obtivemos, podemos observar que nessa expressão o intercepto (β_0) é de **-859719,30**, apontando que na ausência de todos os outros fatores a regressão estima que há um número de ocorrências criminais negativo, o que indica que o modelo falhou em estimar o coeficiente corretamente, já que a variável **número de ocorrências** não admite valores negativos. O valor encontrado possui essa característica provavelmente por

conta de erros no modelo, havendo fatores não observáveis no termo de erro que comprometem a estimação do intercepto.

No parâmetro salário mínimo, encontramos um coeficiente de **387,9325**, indicando que um aumento de uma unidade no salário mínimo provoca uma diminuição de **387,9325** no número de ocorrências criminais. Em outras palavras, existe uma relação inversa entre o salário mínimo e o número de ocorrências criminais, o que, à primeira vista, é favorável à nossa hipótese central. Para a variável *taxa de desemprego* o coeficiente foi de **43.829,35**, o que significa que um aumento de uma unidade na taxa de desemprego acarreta em um aumento do número de ocorrências de mesmo valor do coeficiente respectivo, o que vai de encontro à nossa hipótese formulada. Já para *grau de informalidade*, o coeficiente foi positivo e na magnitude **2.002.340**, indicando que um aumento no grau de informalidade ocasiona um aumento no número de ocorrências criminais em **2.002.340**, o que era esperado, segundo nossa hipótese. Para *anos de estudo* o coeficiente é de **143.820,6** e possui um resultado contraditório às nossas hipóteses iniciais, já que esse sinal indica um aumento em 143.820,6 no número de ocorrências a cada aumento de unidade de anos de estudo, enquanto esperávamos que o impacto fosse negativo. Para a variável *número de domicílios pobres*, podemos intuir que um aumento de uma unidade no número de domicílios pobres está associado a um aumento de **0,140083** no número de ocorrências criminais, o que vai de encontro à hipótese formulada inicialmente. Para a variável *PIB SP*, podemos inferir que um aumento de uma unidade no Produto Interno Bruto (PIB) de São Paulo está associado a um aumento de **0,005140337** no número de ocorrências criminais, o que contraria nossa hipótese. Para a variável *Bolsa Família*, com o sinal positivo do coeficiente estimado podemos interpretar que um aumento de uma unidade no benefício do programa Bolsa Família promove um aumento de **0,001642811** no número de ocorrências criminais, o que contraria nossa hipótese inicial.

3.2. Interpretação dos Resultados

O coeficiente de determinação, também conhecido como R-quadrado, é uma medida estatística que indica a “proporção da variação amostral da variável dependente explicada pelas variáveis independentes utilizada como uma medida de grau de ajuste do modelo” (WOOLDRIDGE, 2019, p. 123). Pela equação utilizada, obtivemos um valor de 0,9845, isto é, aproximadamente 98,45% da variabilidade do número de ocorrências pode ser explicada pelas variáveis explicativas presentes no modelo. Esse valor indica que o modelo obteve sucesso ao prever o número de ocorrências utilizando-se das variáveis independentes empregadas, no

entanto, por si só, essa estatística de análise não indica a causalidade ou a validade do modelo, assim vamos continuar com nossas análises.

O *p-valor* encontrado após rodarmos a regressão linear múltipla é de 0.0004189, isto significa que “a probabilidade de observar uma estatística *t* tão extrema quanto aceitaríamos se a hipótese nula fosse verdadeira” (WOOLDRIDGE, 2019, p. 151) é de 0,04189%. No caso do nosso modelo isso significa que para os níveis de significância de 1%, 5% e 10% o modelo se demonstrará estatisticamente significativo, como informado na tabela a seguir.

| nível de significância | 1% | 5% | 10% |
|------------------------|--------------------------------|--------------------------------|--------------------------------|
| <i>p-valor</i> | Estatisticamente significativo | Estatisticamente significativo | Estatisticamente significativo |

Figura 4. Tabela de análise do p-valor.

A seguir verificaremos a estatística F calculado para o modelo. Esta “é usada para testar a hipótese nula de que todas as variáveis independentes do modelo não têm efeito conjunto na variável dependente contra a hipótese alternativa de que pelo menos uma variável independente tem um efeito significativo” (WOOLDRIDGE, 2019, p. 169). O valor F-estatístico que obtivemos a partir do R foi de 39,65, assim conseguimos concluir por meio de cálculos da estatística F crítica para os níveis de significância 1%, 5% e 10% que o modelo é estatisticamente significativo.

| | valor crítico | significância |
|-----|---------------|--------------------------------|
| 1% | 7,583 | Estatisticamente significativo |
| 5% | 4,737 | Estatisticamente significativo |
| 10% | 3,348 | Estatisticamente significativo |

Figura 5. Tabela de análise da Estatística F.

3.3. Teste de Hipóteses

Assumindo distribuição normal para os resíduos obtidos, ou seja, tomando como verdadeira a sexta hipótese de MQO, podemos realizar testes de hipóteses em nosso modelo, por meio do cálculo da estatística *t* para cada coeficiente estimado das variáveis independentes, assim como para o intercepto. Os testes são unicaudais, seguindo a teoria exposta na seção de Formulação de Hipóteses. Para a variável explicativa central de nossa análise, Salário Mínimo,

foram formuladas duas hipóteses: a objetivo de nosso trabalho, de que o salário mínimo impacta negativamente a criminalidade, e a sua contrária, de que essa política promove um aumento na criminalidade. As tabelas a seguir apresentam, respectivamente, as hipóteses formuladas para cada coeficiente e os resultados dos testes realizados para os níveis de significância de 1%, 5% e 10%. A primeira hipótese citada para a variável Salário Mínimo e seu coeficiente está descrita como “Salário Mínimo”, enquanto que a segunda está representada como “Salário Mínimo 2”.

| | Ocorrências (Criminalidade) | Intercepto | Salário Mínimo | Taxa de Desemprego | Grau de Informalidade | Anos de Estudo | Coeficiente de Gini | Pobreza - Nº de domicílios | PIB SP | Bolsa Família |
|---------------------------|-----------------------------|------------|---|---------------------|-----------------------|---------------------|---------------------|----------------------------|---------------------|---------------------|
| Período encontrado | 1999-2003 | - | 1940-2023 | 1992-2014 | 1993-2014 | 1988-2014 | 1988-2014 | 1988-2014 | 1999+2001+2002-2020 | 1988-2014 |
| Hipótese formulada | - | positivo | afeta negativamente/ afeta positivamente | afeta positivamente | afeta positivamente | afeta negativamente | afeta positivamente | afeta positivamente | afeta negativamente | afeta negativamente |
| H1 | - | b0>0 | b1 <0/ b1>0 | b2 >0 | b5>0 | b3<0 | b6>0 | b4>0 | b7<0 | b4<0 |

Figura 6. Tabela com o período encontrado, hipótese formulada e H1 para cada variável independente, além do intercepto

| Variável | 1% | 5% | 10% |
|----------------------------------|--------------------------------------|--------------------------------------|--------------------------------------|
| Intercepto | Não estatisticamente significante | Não estatisticamente significante | Não estatisticamente significante |
| Salário Mínimo | Não estatisticamente significante | Não estatisticamente significante | Não estatisticamente significante |
| Salário Mínimo 2 | Não estatisticamente significante | Não estatisticamente significante | Não estatisticamente significante |
| Taxa de Desemprego | Estatisticamente significante | Estatisticamente significante | Estatisticamente significante |
| Grau de Informalidade | Não estatisticamente significante | Não estatisticamente significante | Não estatisticamente significante |
| Anos de Estudo | Não estatisticamente significante | Não estatisticamente significante | Não estatisticamente significante |
| Coeficiente de Gini | Não estatisticamente significante | Estatisticamente significante | Estatisticamente significante |
| Nº Domicílios Pobres | Estatisticamente significante | Estatisticamente significante | Estatisticamente significante |
| Bolsa Família | Não estatisticamente significante | Não estatisticamente significante | Não estatisticamente significante |
| Modelo (p-valor) | Estatisticamente significante | Estatisticamente significante | Estatisticamente significante |

Figura 7. Resultado dos testes de hipóteses.

Ao aplicar os testes de hipóteses, concluímos que os coeficientes das variáveis Salário Mínimo, Grau de Informalidade, Anos de Estudo, Coeficiente de Gini, Bolsa Família e o intercepto não são estatisticamente significativos para os níveis de significância de 1%, 5% e 10%, ou seja, segundo o modelo os resultados estimados não contribuem para explicar a criminalidade, a variável de interesse, a esses níveis de significância. Já as variáveis Taxa de Desemprego e Nº de Domicílios Pobres se demonstraram estatisticamente significativas para os níveis de 1%, 5% e 10%, enquanto que a variável Coeficiente de Gini foi encontrada

estatisticamente significativa apenas para os níveis de 5% e 10%. Vale notar que para ambas as hipóteses para Salário Mínimo seu coeficiente se demonstrou não estatisticamente significativo, para os níveis de significância utilizados.

4. Discussão e Conclusão

Partindo da hipótese de que políticas de salário mínimo contribuem para a diminuição da criminalidade, utilizamos um modelo de regressão linear múltipla para verificar a veracidade de tal hipótese, levando-se em consideração a possibilidade de a hipótese contrária ser verdadeira: de que o salário mínimo promove um aumento na criminalidade. Tal hipótese contrária é confirmada por Fone et al. (2019). A área analisada foi o Estado de São Paulo, no período de 1999 a 2014, excetuando-se os anos de 2000 e 2010.

A partir de métricas utilizadas para verificar a qualidade do modelo, a estimação do R^2 e o cálculo da estatística F, concluímos que o modelo exita em explicar a variável de interesse criminalidade, para a qual foi utilizada uma variável proxy, número de ocorrências de um grupo selecionado de tipos de crimes. O coeficiente de determinação R^2 encontrado foi de 0,9845, um resultado satisfatório, enquanto que a estatística F calculada foi de 39,45, valor acima dos F's críticos encontrados para os níveis de significância de 1%, 5% e 10%, o que indica que as variáveis explicativas têm um efeito conjunto sobre a variável de interesse.

Com os resultados obtidos pela técnica de regressão linear múltipla, aplicamos testes de hipóteses para verificar se as hipóteses formuladas por nós, com base em artigos relacionados ao tema, se confirmariam ou não, utilizando-se da estatística t para cada variável independente, além do intercepto. Para a variável explicativa central de nossa análise, Salário Mínimo, foram formuladas duas hipóteses: a objetivo de nosso trabalho, de que o salário mínimo impacta negativamente a criminalidade, e a sua contrária, de que essa política promove um aumento na criminalidade. A última foi confirmada por Fone et al. (2019) em seu artigo.

Os resultados dos testes de hipóteses foram desfavoráveis para o objetivo do trabalho, já que o coeficiente da variável Salário Mínimo demonstrou-se não estatisticamente significativo para os níveis de significância de 1%, 5% e 10%. Portanto, nosso teste concluiu que não há evidências para se afirmar que a política de Salário Mínimo impacta negativamente a criminalidade. No entanto, ao testarmos a hipótese contrária, de que essa política impacta positivamente a criminalidade, também concluímos que o coeficiente demonstrou-se não estatisticamente significativo para os níveis de significância de 1%, 5% e 10%, ou seja, que não

há evidências para se afirmar que a política de Salário Mínimo impacta positivamente a criminalidade.

Tal conclusão pode ser explicada por algumas hipóteses de problemas, como: erros intrínsecos ao modelo, relacionado a violações das hipóteses de MQO, assim causando viés nos coeficientes estimados; seleção incorreta das variáveis independentes; número de observações insuficiente para o método, apesar de ser igual ao utilizado por Beauchamp e Chan (2014); problemas ligados à aplicação do Método de Mínimo Quadrados em uma série temporal, como explicado na seção de Considerações na Estimação por MQO em Séries Temporais; e, por fim, a falsa suposição de que a relação entre salário mínimo e criminalidade pode ser modelada como uma regressão linear múltipla. Braun (2017), em estudo de proposta equivalente à nossa, encontrou evidências empíricas de que o salário mínimo possui um efeito sobre a criminalidade em forma de U, o que pode explicar o fato de não termos encontrado evidências para dizer se o salário mínimo promove um efeito positivo ou negativo sobre o salário mínimo.

4.Referências Bibliográficas

- DeLosso, R. (2020). Deflacionamento. *Revista de Economia Aplicada*, 24(478).
- Braun, C. (2019). Crime and the minimum wage. *Review of Economic Dynamics*, 32, 122-152.
- Fone, Z. S., Sabia, J. J., & Cesur, R. (2019). Do minimum wage increases reduce crime? National Bureau of Economic Research, Working Paper Series, 25647.
- Beauchamp, A., & Chan, S. (2014). The minimum wage and crime. *The B.E. Journal of Economic Analysis & Policy*, 14(3).
- Wooldridge, J. M. (2019). *Introdução à Econometria: Uma Abordagem Moderna*. São Paulo: Cengage Learning.
- Does Crime Affect Economic Growth? Claudio Detotto, Edoardo Otranto
- PINTO, Antonio Marcos; FARIAS, Joedson Jales; COSTA, Rodolfo Ferreira; LIMA, Francisco Soares. Uma análise dos determinantes da taxa de crimes de homicídios nos estados do Brasil: uma aplicação em painel dinâmico. *Revista de Economia Regional, Urbana e do Trabalho*, v. 7, n. 2, 2018.